

Notes LLMKL

Kylliann De Santiago

Idées de la méthode :

- ▶ L'idée est de combiner un maximum de méthodes afin d'extraire le plus d'information possible.
- ▶ La méthode LLMKL se base sur : “self-expressiveness graph”, Structure globale des données, structure de graphe locale, Noyaux Consensus.
- ▶ Objectif : Construire une matrice d'affinité Z qui permettra de faire un clustering efficace à partir de ces différents axes.

self-expressiveness graph

- ▶ L'idée : Construire une matrice d'affinité Z qui associera de grandes valeurs aux observations du même sous-espace.
- ▶ On cherche Z tel que :

$$\min_Z \frac{1}{2} \|X - XZ\|_F^2 + \alpha R(Z), \text{ où } Z \geq 0, \text{ diag}(Z) = 0$$

On rappelle que :

$$\langle A, B \rangle_F = \text{Tr}(A^* B) = \text{Tr}(B A^*) \text{ et } \|A\|_F^2 = \text{Tr}(A^* A)$$

Avec cette formulation, nous saisissons mal les données non linéaire, on peut reformuler le problème ainsi :

$$\min_Z \frac{1}{2} \|\phi(X) - \phi(X)Z\|_F^2 + \alpha R(Z)$$

où $Z \geq 0$, $\text{diag}(Z) = 0$ et ϕ est une fonction noyau.

$$\min_Z \frac{1}{2} \|\phi(X) - \phi(X)Z\|_F^2 + \alpha R(Z)$$

En développant la norme :

$$\min_Z \|\phi(X)\|_F^2 + \langle \phi(X), \phi(X)Z \rangle_F + \|\phi(X)Z\|_F^2 + \alpha R(Z)$$

D'où :

$$\min_Z \text{Tr}[\phi(X)^T \phi(X)] + 2 \text{Tr}(\phi(X)^T \phi(X)Z) + \text{Tr}[(\phi(X)Z)^T \phi(X)Z] + \alpha R(Z)$$

Finalement :

$$\min_Z \text{Tr}(H + 2 HZ + Z^T HZ) + \alpha R(Z)$$

s.c. $Z \geq 0$, $\text{diag}(Z) = 0$.

On notera que $\phi(X)^T \phi(X) = H$, $X \in \mathbb{R}^{p \times n}$ et $H \in \mathbb{R}^{n \times n}$

Global structure

- ▶ On souhaite que H soit de faible rang. On impose donc en plus un coefficient :

$$\beta \|\phi(X)\|_*$$

- ▶ Puisque $H = \phi(X)^T \phi(X)$ alors $\text{rang}(H) = \text{rang}(\phi(X))$. Donc, minimiser $\|\phi(X)\|_*$ équivaut à minimiser $\|H\|_*$
- ▶ De plus, H est une matrice symétrique et semi-définie positive alors $\exists B, H = B^T B$
- ▶ Donc, minimiser $\|H\|_*$ revient à minimiser $\|B\|_*$.

La matrice B peut capturer la structure globale des données dans l'espace engendré par H .

Notre matrice d'affinité devient donc :

$$\min_{Z, B} \text{Tr}(H + 2 HZ + Z^T HZ) + \alpha R(Z) + \beta \|B\|_*$$

$$\text{s.c. } Z \geq 0, \text{ diag}(Z) = 0, B^T B = H.$$

Local structure

L'idée de cette partie est d'ajouter une nouvelle pénalisation à partir d'un coefficient directement relié à la structure locale des données.

On commence par définir le graphe complet D tel que $D_{ij} = \|X_i - X_j\|_2^2$ où chaque individu est considéré comme un noeud, et chaque lien entre deux noeud correspond à l'affinité entre les deux individus.

On définit :

$$R(Z) = \min_Z \sum_{i,j=1}^n \|X_i - X_j\|_2^2 Z_{ij}$$

$$R(Z) = \min_Z \sum_{i=1}^n \sum_{j=1}^n D_{ij} Z_{ij}$$

Donc :

$$R(Z) = \min_Z \text{Tr}(D^T Z)$$

Consensus Kernel

L'idée de cette partie est de trouver un noyau consensus H proche du mélange de r noyaux : $\{H_i\}_1^r$.

Autrement dit, on souhaite trouver H tel que (MKL weighting strategy) :

$$\min_{H, g} \|H - \sum_{i=1}^r g_i H_i\|_F^2$$

s.c. $g_i \geq 0$ et $\sum_{i=1}^r g_i = 1$

Fonction d'objectif :

Une autre idée a été de décomposer H tel que $H = B^T B + E$ où E est une matrice de bruit.

En agrégeant les idées, on aboutit à la fonction d'objectif suivante :

$$\min_{Z, B, H, E, g} \text{Tr}[(I + 2Z + Z^T Z)B^T B] + \lambda_1 \|B\|_* \\ + \lambda_3 \text{Tr}(D^T Z) + \frac{\lambda_2}{2} \|H - \sum_{i=1}^r g_i H_i\|_F^2 + \lambda_4 \|E\|_1$$

s.c. $Z > 0$, $g_i \geq 0$, $\sum_{i=1}^r g_i = 1$, $H = B^T B + E$, $\text{diag}(Z) = 0$, $Z^T \mathbf{1} = \mathbf{1}$ (1 vectoriel).

Résumé :

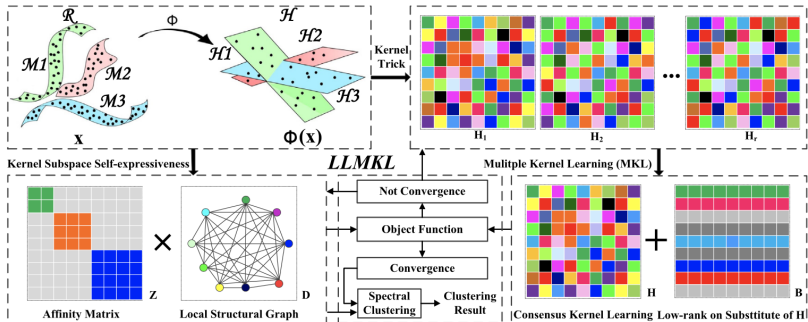


Fig. 1. The block diagram of the proposed LLMKL method.

Algorithm : ---

Algorithm 1 Solving LLMKL for clustering via ADMM.

Input: Data matrix \mathbf{X} , r base kernel matrices $\{\mathbf{H}_i\}_{i=1}^r$, and tradeoff parameters $\lambda_1, \lambda_2, \lambda_3, \lambda_4$.

Initialize: $\mathbf{Z}^1 = \mathbf{0}$, $\mathbf{E}^1 = \mathbf{0}$, $\mathbf{H}^1 = \frac{1}{r} \sum_{i=1}^r \mathbf{H}_i$, $\{\mathbf{g}_i^1\}_{i=1}^r = \frac{1}{r}$, $\varepsilon = 10^{-6}$, $t = 1$, $\mu_{max} = 1e10$, $\mu = 0.1$, $\eta = 20$, and $maxIter = 1e3$.

- 1: **while** convergence criterion is not satisfied, and $t < maxIter$
do
- 2: Update \mathbf{Z}^{t+1} by using (14).
- 3: Update \mathbf{B}^{t+1} by using (20).
- 4: Update \mathbf{H}^{t+1} by using (16).
- 5: Update \mathbf{E}^{t+1} by using (23).
- 6: Update \mathbf{g}^{t+1} by using (25).
- 7: Update \mathbf{Y}_1^{t+1} and μ^{t+1} by using (26).
- 8: $t = t+1$;
- 9: **end while**
- 10: Define balanced affinity matrix $\mathbf{Z} = \frac{1}{2}(\mathbf{Z} + \mathbf{Z}^T)$.
- 11: Perform spectral clustering by using (27).

Output: The clustering results: ACC, NMI, Purity.